

UT 6. Procesamiento de Lenguaje Natural (PLN)

Curso de Especialización IA y Big Data

**¿Cómo entiende
ChatGPT lo que
escribes?**

¿Qué es el Procesamiento de Lenguaje Natural?

El puente tecnológico que permite a las máquinas comunicarse como nosotros.



Rama de la IA

Disciplina de la IA enfocada en la interacción con el lenguaje humano natural.



Capacidades

Permite a los sistemas entender, analizar y generar texto de forma coherente y contextual.



Fusión Técnica

Combina la riqueza de la lingüística con el poder del Machine Learning para procesar grandes volúmenes de datos.

¿Qué es el Procesamiento de Lenguaje Natural?

El desafío de convertir el caos textual en inteligencia de negocio.

80%

**de los datos mundiales son
texto no estructurado**



Fuentes Principales

Emails, documentos, chats y redes sociales.



Gran valor estratégico

Información crítica para la toma de decisiones en empresas modernas.

¿Qué es el Procesamiento de Lenguaje Natural?

APLICACIONES PRACTICAS



Chatbots y Asistentes

Interacción fluida y automatizada para soporte y servicio al cliente.



Análisis de Sentimiento

Identificación de emociones y opiniones en grandes volúmenes de texto.



Traducción Automática

Eliminación de barreras lingüísticas mediante traducción en tiempo real.



Sistemas de Búsqueda

Recuperación inteligente de información basada en semántica y contexto.

Fundamentos

Conceptos básicos para la estructura y el análisis en PLN.



Corpus

Conjunto amplio y estructurado de textos utilizado para el entrenamiento de modelos.



Documento

Unidad individual de información dentro de un corpus (ej. un email o un artículo).



Tokens

Unidad mínima de texto. Pueden ser palabras, símbolos o sub-palabras.



NER

Reconocimiento de entidades:
Identificación de personas, lugares y organizaciones.

PLN, ¿por qué es un reto?

El PLN traduce el mundo humano al mundo matemático, superando la ambigüedad y desestructuración del lenguaje natural. Las máquinas entienden números (ceros y unos), pero los humanos usamos un lenguaje ambiguo y desestructurado.

NLU (Comprensión)

Extraer significado e intención

- ✓ Análisis de sentimiento
- ✓ Extracción de entidades
- ✓ Categorización de texto



NLG (Generación)

Redactar y generar texto nuevo

- ✦ Chatbots inteligentes
- ✦ Traducción automática
- ✦ Resúmenes automáticos



El PLN es el puente entre ambos mundos.

Mapa de Ruta: Nuestro Viaje en PLN

De enseñar a la máquina a leer texto básico a interactuar con Modelos de Lenguaje Masivos (LLMs).



01.

Preprocesamiento



Preparar el dato:
Tokenización y
normalización.



02. ML Clásico

Clasificar el dato:
Naive Bayes y TF-IDF.



03. Embeddings

Entender el contexto:
Vectores densos y
Semántica.



04. IA Generativa

LLMs y
Transformers:
Creación y RAG.

01.

Preprocesamiento

El Pipeline de Preprocesamiento

Los datos reales están "sucios" (HTML, emojis, errores). Este flujo es obligatorio antes de cualquier modelo.



Texto Ruidoso

Datos originales con:

- Etiquetas HTML
- Emojis
- Errores ortográficos



1. Fase de Limpieza

Normalización básica: conversión a minúsculas, eliminación de puntuación y filtrado de stop words semánticamente vacías.



2. Lematización

Proceso morfológico para reducir palabras a su raíz (lema). Crucial para unificar conceptos y reducir el vocabulario.



Texto Limpio

Dato listo para el modelo:

- Estructurado
- Normalizado
- Semánticamente denso

Antes de aplicar IA, el texto crudo debe limpiarse. Si entra "basura", el modelo escupe "basura"

Preprocesamiento

Tokenización

Dividir frases en unidades operables (tokens o sub-palabras) para que el modelo pueda procesar el lenguaje.

Stop Words

Palabras frecuentes (artículos, preposiciones) con baja carga semántica que se eliminan para optimizar la memoria y el enfoque.



Ejemplo: "El gato corre muy rápido." → **[gato, corre, rapido]**



Normalización

Técnicas para reducir las palabras a su forma base y disminuir el vocabulario del sistema y su complejidad.

Stemming

Truncamiento mecánico y agresivo de sufijos sin considerar el contexto lingüístico. Corta la palabra "a lo bruto" para extraer una raíz (ej. "corriendo" → "corr"). **Rápido pero impreciso**

Lematización

Análisis morfológico profundo que utiliza diccionarios para hallar la raíz semántica (lema). Ej. "fui" → "ser") **Lento pero exacto**

EJEMPLOS COMPARATIVOS

Palabra: "comiendo"

comi

STEMMING

comer

LEMATIZACIÓN

Palabra: "jugaremos"

jug

STEMMING

jugar

LEMATIZACIÓN

Etiquetado Gramatical (POS)

Identificación de la categoría gramatical de cada palabra y sus rasgos morfológicos dentro de una oración.

Análisis Morfológico

Desglose de palabras en sus componentes (lexemas y morfemas) para determinar género, número, tiempo, modo y persona.

Etiquetado POS

Asignación de etiquetas (tags) como Sustantivo, Verbo o Adjetivo basándose en la definición de la palabra y su contexto.

EJEMPLO DE ANÁLISIS SINTÁCTICO-MORFOLÓGICO

"El modelo aprende muy rápido."

El

Art/Det

modelo

Nombre

aprende

Verbo

muy

Adverbio

rápido

Adjetivo

Reconocimiento de Entidades (NER)

Escaneo y extracción de conceptos del mundo real para convertir texto libre en datos estructurados.

Extracción de Información

El sistema identifica, extrae y categoriza automáticamente elementos clave. Es indispensable para organizar bases de datos a partir de narrativas no estructuradas, permitiendo al modelo entender "quién", "dónde" y "cuánto".

EJEMPLO DE CATEGORIZACIÓN NER

"Elon Musk fundó SpaceX en California con una inversión inicial considerable."

Elon Musk

PERSONA

SpaceX

ORGANIZACIÓN

California

UBICACIÓN

Inversión Monetaria

CANTIDAD / MONEDA

Etiquetas: POS y NER

Referencia técnica de las categorías gramaticales y entidades nombradas estándar en PLN.

Etiquetado POS (Universal)

NOUN / PROPN Sustantivo común / Nombre propio

VERB / AUX Verbo léxico / Verbo auxiliar

ADJ / ADV Adjetivo / Adverbio

PRON / DET Pronombre / Determinante

ADP / CONJ Preposición / Conjunción

NUM / SYM Numeral / Símbolo matemático

PUNCT / INTJ Puntuación / Interjección

Categorías NER (Estándar)

PER / PERSON Personas reales o ficticias

ORG Empresas, instituciones, agencias

LOC / GPE Localizaciones, países, ciudades

DATE / TIME Fechas, periodos, horas específicas

MONEY / CURR Valores monetarios y divisas

QUANTITY Medidas, peso, distancia, etc.

MISC Eventos, obras, leyes, otros

Expresiones Regulares (Regex)

Patrones lógicos utilizados para la búsqueda, validación y extracción de datos estructurados en texto bruto.

Validación

Asegurar que un texto cumple un formato específico (ej. emails, DNIs o números de teléfono).

Búsqueda

Localizar patrones complejos dentro de grandes volúmenes de datos que no son literales.

Extracción

Convertir información no estructurada en campos de datos listos para procesar.

SINTAXIS Y METACARACTERES COMUNES

Símbolo	Significado	Ejemplo
.	Cualquier carácter individual	<code>a.c</code> → <code>abc</code> , <code>a1c</code>
<code>\d</code>	Cualquier dígito (0-9)	<code>\d{3}</code> → <code>123</code> , <code>987</code>
<code>^</code> / <code>\$</code>	Inicio y fin de línea	<code>^Hola</code> / <code>final\$</code>
<code>+</code> / <code>*</code>	1 o más / 0 o más repeticiones	<code>lo+</code> → <code>lo</code> , <code>loo</code>

Regex: Casos de Uso Prácticos

Implementación de patrones para la validación de documentos oficiales y búsqueda avanzada de términos específicos.

Validación de DNI

Garantiza que el documento introducido cumple el estándar español: 8 dígitos seguidos de una letra de control (A-Z).

Búsqueda de Términos

Localización dinámica de palabras que contienen caracteres específicos (como la 'x') en cualquier posición dentro de un bloque de texto.

DETALLE TÉCNICO DE LOS PATRONES

EXPRESIÓN DNI

`^\d{8}[A-HJ-NP-TV-Z]$`

Valida 8 números y letra (omitiendo I, O, U, Ñ)

EXPRESIÓN BÚSQUEDA 'X'

`\b\w*x\b`

Encuentra: "éxito", "texto", "exacto", "examen"

PRACTICA 1 y 2

02. Vectorización y ML Clásico

El Siguiente Paso: De Palabras a Números

Transición al ML Clásico

Tras entender la estructura lingüística (POS, NER), debemos convertir el lenguaje en algo que las máquinas puedan procesar matemáticamente.

- Representación matricial del texto.
- Algoritmos estadísticos de clasificación.
- Paso previo a los modelos profundos.



Bag of Words (BoW)

¿En qué consiste?

Crea un vocabulario general y cuenta cuántas veces aparece cada palabra en un documento. Es la base de la vectorización clásica en PLN. Es el primer algoritmo de conversión.

CRÍTICA Y LIMITACIÓN TÉCNICA

Sin contexto semántico:

El modelo BoW no entiende la gramática ni el orden. Las frases "Juan come pescado" y "El pescado come a Juan" resultan en vectores idénticos.



Vectorización TF-IDF

Mejora respecto a BoW

Reduce la influencia de términos comunes y resalta aquellos más raros y significativos para un texto en particular.

PONDERACIÓN TF-IDF

Resuelve el sesgo de las palabras recurrentes que dominan el vector.

TF (Term Frequency):

Frecuencia del término en el documento.

IDF (Inverse Document Frequency):

Rareza del término en el corpus global. Premia lo específico y discrimina lo genérico.

Importancia Relativa (Ejemplo Medicina)

paciente (Raro/Clave)

diagnóstico

clínico



además (Muy común)



pero (Stopword)

Vectorización TF-IDF


Identificación de Keywords

Un término frecuente en un documento pero raro en el corpus obtiene un peso **TF-IDF excepcionalmente alto**, actuando como palabra clave discriminadora.

PROCESAMIENTO Y CLASIFICACIÓN

Convertimos el corpus en una **matriz dispersa multidimensional** con normalización L2 para equiparar longitudes.

Posteriormente, aplicamos algoritmos de **Machine Learning** para la clasificación de los datos vectorizados.



Caso de Uso: Sentiment Analysis

Clasificación de opiniones y redes sociales según su polaridad (positiva, negativa o neutra).

Palabras como Dimensiones


Ejes de Datos

Cada palabra única en el diccionario funciona como una **dimensión individual** (un eje) en un mapa matemático de alta complejidad.

MAPPING SEMÁNTICO

Puntos en el mapa: Cada oración o documento se convierte en una coordenada específica dentro de este espacio infinito.

Significado: La cercanía física entre dos puntos indica que los textos comparten temas o vocabularios similares.



Espacio Vectorial

Representación geométrica donde el lenguaje se transforma en distancias matemáticas calculables.

¿Porqué dispersa?



Muchos ceros

Un idioma tiene 100,000 palabras, pero un texto corto solo usa 50. El 99.9% de nuestra matriz estará llena de ceros.



Eficiencia

Una "matriz dispersa" es una técnica para ahorrar memoria ignorando esos ceros y guardando solo los datos útiles.

La matriz de frecuencia

Así se ve la transformación inicial: contamos cuántas veces aparece cada palabra

Documento	"Inteligencia"	"Datos"	"Modelo"	"Clima"
Doc 1: Tecnologia	5	12	3	0
Doc 2: Meteorologia	0	2	1	18
Doc 3: Algoritmos	8	4	7	0

Modelos de Clasificación Clásica

TF-IDF + Machine Learning


Uso de matrices TF-IDF como entrada para algoritmos de aprendizaje automático estadístico para categorizar texto.

ALGORITMOS PRINCIPALES

Naive Bayes: Robusto para detección de Spam basado en cálculos de probabilidad e independencia de características.

SVM: Máquinas de Vectores de Soporte que trazan hiperplanos óptimos para separar clases semánticas.

Frontera de Decisión (SVM)



Algoritmo Naive Bayes

¿Qué es Naive Bayes?

Un clasificador probabilístico basado en el Teorema de Bayes que asume independencia entre características. Es extremadamente eficiente para procesar grandes volúmenes de texto.

FUNDAMENTO MATEMÁTICO

$$P(A|B) = P(B|A) \cdot P(A) / P(B)$$

En términos sencillos:

- **¿Qué probabilidad hay de que sea A?** dado que ha ocurrido B.
- **Depende de:** la frecuencia previa de A y cómo de común es B en casos de A.

Eficacia en Filtrado de Spam

Destaca por su robustez ante la alta dimensionalidad del lenguaje natural, siendo el estándar para detectar correos no deseados.

Naive Bayes: El Poder de la Probabilidad

¿Cómo funciona?

Es un algoritmo "ingenuo" (naive) porque asume que cada palabra o característica es independiente de las demás. Calcula la probabilidad de que un elemento pertenezca a una categoría basándose en la frecuencia de sus rasgos.

EJEMPLO: CLASIFICADOR DE SPAM

Si recibes un correo con las palabras **"Premio"** y **"Gratis"**:

1. Mira cuántas veces "Premio" aparece en Spam vs. Legítimo.
2. Mira la frecuencia de "Gratis" en ambas categorías.
3. Multiplica las probabilidades.

$$P(\text{Spam} \mid \text{Palabras}) > P(\text{OK})$$

Resultado: El correo se marca como SPAM



Clave del éxito

Su simplicidad lo hace increíblemente rápido y eficaz para clasificar texto en tiempo real.

SVM: Máquinas de Vectores de Soporte

¿Cómo funcionan las SVM?

Algoritmos de aprendizaje supervisado que buscan el **hiperplano óptimo** para separar clases. Son especialmente potentes para manejar datos complejos y de alta dimensionalidad. Imagina que quieres separar dos grupos de datos (como manzanas y naranjas). Una SVM busca la **línea (o hiperplano) ideal** que deje el mayor pasillo libre entre ambos grupos.

CONCEPTOS FUNDAMENTALES

Vectores de Soporte: Los puntos más cercanos a la frontera que definen la posición del hiperplano.

Margen Máximo: El algoritmo maximiza la distancia entre las clases para mejorar la generalización.

Truco del Kernel: Transforma datos no lineales a una dimensión superior para hacerlos separables.

Ventaja Principal


Eficaz en espacios de gran dimensionalidad, incluso cuando el número de dimensiones es mayor que el de muestras.

SVM: El Clasificador de la "Frontera Inteligente"

EJEMPLO: DETECTOR DE FRUTA MADURA

1. **Los Datos:** Analizamos "Color" y "Firmeza".
2. **Vectores de Soporte:** Son las frutas más "difíciles" (las que están justo en el borde de ser maduras o verdes).
3. **El Margen:** La SVM crea una frontera ancha para no equivocarse con frutas nuevas.

¡Precisión máxima incluso con pocos datos!



Por qué usar SVM

Es excelente cuando los datos son complejos y necesitamos una separación clara y robusta que generalice bien.

Métricas: Validando la Generalización del Modelo

INTERPRETACIÓN DE MÉTRICAS DE DESEMPEÑO

1. Matriz de Confusión

Herramienta visual que desglosa los aciertos (VP, VN) y errores (FP, FN) del modelo. Permite identificar si el sistema confunde clases específicas.

3. Sensibilidad (Recall)

Capacidad de detectar todos los casos positivos. Crítica en medicina para no pasar por alto patologías.

$$VP / (VP + FN)$$

2. Precisión (Precision)

¿Qué tan fiable es el modelo cuando predice positivo? Mide la calidad de las predicciones positivas.

$$VP / (VP + FP)$$

4. F1-Score

Media armónica entre Precisión y Recall. Es el mejor indicador para validar la robustez global en conjuntos desbalanceados.

$$2 * (Prec * Rec) / (Prec + Rec)$$



Punto de Control Técnico

La validación rigurosa mediante estas métricas garantiza que el modelo no solo memorice (overfitting) sino que generalice ante datos reales e invisibles.

PRACTICA 3

03. Embeddings

Hacia la Semántica Profunda: Embeddings

TRANSICIÓN: DE LA ESTADÍSTICA AL SIGNIFICADO

¿Por qué es necesario el cambio?

Los modelos clásicos (TF-IDF, BoW) presentan limitaciones críticas que el Deep Learning viene a resolver:

- **Explosión de Dimensionalidad:** Las matrices dispersas crecen con el vocabulario, volviéndose ineficientes.
- **Independencia Semántica:** Para un modelo clásico, "coche" y "automóvil" son tan distintos como "coche" y "manzana" (ortogonalidad).
- **Pérdida de Contexto:** Se ignora el orden y la relación fluida entre palabras.

La llegada de los Word Embeddings permite proyectar el lenguaje en un espacio continuo donde la cercanía geométrica equivale a similitud conceptual.



Hacia la Semántica Profunda: Embeddings

¿Cómo definirías a una persona usando números? (**Agilidad: 0.9, Fuerza: 0.8**). Si una persona es un vector de 5 números, **una palabra es un vector de 300 números**. Los embeddings capturan rasgos invisibles.

PERFIL DE PERSONA

Fuerza



Magia



Agilidad



Vector Persona = [0.8, 0.6, 0.9, 0.4, 0.7]



EMBEDDING: "PIZZA"



Sabor (Salado)



Italiana




Circularidad



Vector Word = [0.9, 0.97, 0.85, ... 297
dimensiones más]

Hacia la Semántica Profunda: Embeddings

ESPACIO VECTORIAL



Compresión de Significado

Transformación del lenguaje en **vectores densos** continuos.

Cada palabra es un punto en el espacio. La distancia geométrica mide la **afinidad conceptual**.

- Adiós a la dispersión.
- Significado matemático.
- Captura de contextos.


Arquitecturas Word2Vec: CBOW vs

Skip-gram

Dos formas de entrenar una red neuronal para obtener *embeddings*.


CBOW (Continuous Bag of Words)

Intenta predecir la **palabra objetivo** basándose en su vecindario de palabras circundantes (contexto).



Skip-gram

Asume una palabra de entrada e intenta predecir el **contexto estadísticamente más probable** que la rodeará.




El Álgebra del Lenguaje

OPERACIONES SEMÁNTICAS EN ESPACIOS DENSOS

Los **embeddings** codifican analogías semánticas mediante sumas y restas matemáticas, permitiendo "calcular" el significado de forma geométrica.

$$\text{Rey} - \text{Hombre} + \text{Mujer} \approx \text{Reina}$$

- **Género:** La diferencia entre "Rey" y "Reina" es la misma que entre "Hombre" y "Mujer".
- **Propiedad:** Vectores paralelos representan la misma relación conceptual (desplazamiento de género).



4. IA GENERATIVA TRANSFORMER

Limitaciones de las Arquitecturas RNN

EL ESTADO DEL ARTE PRE-TRANSFORMER

Antes de la llegada de los Transformers, el estándar eran las **Redes Neuronales Recurrentes (RNN)**. Sin embargo, su diseño presentaba cuellos de botella críticos:

- **Procesamiento Secuencial:** Leían el texto palabra por palabra. Esto impedía la paralelización y el uso eficiente de la potencia de cálculo.
- **Amnesia en Secuencias Largas:** Dificultad para mantener la memoria al principio de párrafos extensos (problema del gradiente desvaneciente).



*Visualización del
procesamiento secuencial:
"Mirada de túnel" palabra a
palabra.*



La Arquitectura Transformer (2017)

UN CAMBIO DE PARADIGMA: ATTENTION IS ALL YOU NEED

El artículo "**Attention is All You Need**" revolucionó el PLN. A diferencia de las RNN, los Transformers procesan el texto en **paralelo**.

- **Auto-Atención:** Calcula la relevancia de cada palabra respecto a las demás.
- **Bidireccionalidad:** Entiende el contexto completo de una frase simultáneamente.
- **Escalabilidad:** Permite entrenar modelos masivos de forma eficiente.

MECANISMO DE AUTO-ATENCIÓN



El modelo conecta "banco" con "dinero" para resolver la polisemia mediante atención semántica.



Familias de Transformers: Encoder vs Decoder

ENCODERS (COMPENSIÓN)

Ejemplo: BERT

Leen en ambas direcciones simultáneamente. Son expertos en analizar el contexto global.

- **Uso:** Clasificación, extracción de datos y comprensión profunda.

BERT (Bidireccional)



DECODERS (GENERACIÓN)

Ejemplos: GPT, Llama

Leen de izquierda a derecha (causales). Su diseño oculta las palabras futuras.

- **Uso:** Predicción de la siguiente palabra y creación de contenido.

GPT (Unidireccional)



*Diferenciación
fundamental del
ecosistema actual*

Cronología y Evolución de los Transformers

HITOS EN LA HISTORIA DEL PLN

Desde la propuesta original en 2017, la arquitectura ha divergido en tres ramas principales según su función:

- **2018 - GPT:** El primer modelo **Decoder-only**, pionero en la generación de texto pre-entrenado.
- **2018 - BERT:** Revolucionó la comprensión con su enfoque **Encoder-only** y bidireccionalidad.
- **2019 - T5 & BART:** Modelos **Encoder-Decoder** que combinan ambas fortalezas para tareas de secuencia a secuencia como la traducción.
- **2020+ - GPT-3 & Llama:** Escalabilidad masiva hacia los Grandes Modelos de Lenguaje (LLMs).
- <https://llmtimeline.web.app/>
- <https://llm-release-dashboard.vercel.app/>



2017 Transformer

2018 GPT / BERT

2019 T5 / DistilBERT

2020 GPT-3

*Genealogía de modelos
pre-entrenados*

Ecosistema de Hugging Face

LA DEMOCRATIZACIÓN DE LOS TRANSFORMERS


Hugging Face se ha consolidado como el **"GitHub de la Inteligencia Artificial"**, unificando el ciclo de vida del ML:

- **Hub Centralizado:** Acceso a miles de modelos pre-entrenados, datasets masivos y espacios interactivos.
- **Librerías Open Source:** Ecosistema integrado (Transformers, Datasets, Accelerate) para simplificar flujos complejos.
- **Pipelines de Python:** Herramienta que encapsula tokenización, modelo y decodificado en solo **3 líneas**.
- <https://huggingface.co/learn/llm-course/chapter1/4>

EJEMPLO DE PIPELINE

```
from transformers import pipeline

classifier = pipeline(
    "sentiment-analysis",
    model="pysentimiento/robertuito-..."
)
```



Simplificación radical del código

4. IA GENERATIVA

LLM

¿Qué es un Large Language Model (LLM)?

Son la evolución masiva de los **Transformers Decoder**.

- Escalados con **miles de millones** de parámetros.
- Entrenados en clústeres masivos de **GPUs**.

Habilidades Emergentes

Al alcanzar cierta escala, los modelos adquieren capacidades que no fueron programadas explícitamente, sino que surgen del entrenamiento masivo.



Ingeniería de Prompts (Prompt Engineering)

En la era de los LLM, la interfaz de programación es el **lenguaje natural**. Si eres vago en tu petición, el modelo será vago en su respuesta.

COMPONENTES DE UN BUEN PROMPT

- 01. Rol asignado
- 02. Instrucción clara
- 03. Contexto
- 04. Restricciones de formato

Ejemplo: "Genera la respuesta exclusivamente en formato JSON."

Prompt Malo

"Resume esto"

Prompt Excelente

"Actúa como un experto en TI. Resume este texto en 3 viñetas. No uses jerga comercial."



Técnicas Avanzadas de Prompting

Zero-Shot Prompting

Ejecución directa sin demostraciones. El modelo utiliza su conocimiento latente para responder a una pregunta o comando simple.

Few-Shot Prompting

Inyección de 2 a 5 pares de ejemplos (entrada/salida) como patrón. Forzamos al modelo a aprender la estructura deseada para tareas específicas.

Chain-of-Thought (CoT)

Forzar la descomposición en razonamiento secuencial ("piensa paso a paso"). Mitiga fallos en lógica, matemáticas y razonamiento complejo.

RAZONAMIENTO ESTRUCTURADO



Control Estocástico (Hiperparámetros)

Los LLMs no son deterministas por defecto; predicen el siguiente token basándose en una distribución de probabilidades **Softmax**.

Temperatura

0.0: Texto determinista y robótico.


1.0: Aplana la distribución, favoreciendo la **creatividad e imprevisibilidad**.

Top-P y Top-K

Estrategias de **Nucleus Sampling** que cortan la "cola larga" de probabilidades bajas para evitar que el modelo genere términos sin sentido o alucinaciones.

Nota Técnica: La temperatura no cambia las probabilidades relativas, sino que las escala antes de aplicar Softmax. Una temperatura de 0.7 suele ser el equilibrio estándar para asistentes de propósito general.

NIVEL DE CREATIVIDAD



Analítico / Código
(Baja Temperatura)

Creativo / Poesía
(Alta Temperatura)

El talón de Aquiles: Alucinaciones

Los modelos no son bases de datos, son **motores estadísticos**. Tienen una fecha de corte de conocimiento y tienden a inventar hechos con total convicción.

Motores Probabilísticos

No recuperan información; predicen la palabra más probable, lo que puede generar errores factuales graves.

Knowledge Cut-off

Su entrenamiento terminó en una fecha fija. Desconocen eventos posteriores y suelen "rellenar" huecos.

¿Por qué ocurre?

- Sobreajuste a patrones lingüísticos sobre la verdad.
- Falta de mecanismos de verificación externa de datos.
- Presión por dar una respuesta en lugar de admitir ignorancia.

SIMULACIÓN DE CHAT

Usuario:

¿Quién ganó el mundial de ajedrez en mayo de 2024?

AI Model:

El Gran Maestro Magnus Carlsen recuperó el título tras vencer a Alireza Firouzja en una final épica celebrada en Oslo el pasado 15 de mayo. 

ANÁLISIS DE LA ALUCINACIÓN:

1. Carlsen no compitió por el título.
2. El evento aún no había ocurrido en la fecha de corte.
3. El modelo inventa nombres, fechas y sedes con total seguridad.

Solución Industrial: Arquitectura RAG

Retrieval-Augmented Generation. En lugar de reentrenar el modelo (Fine-Tuning), le proporcionamos un motor de búsqueda de datos propios.

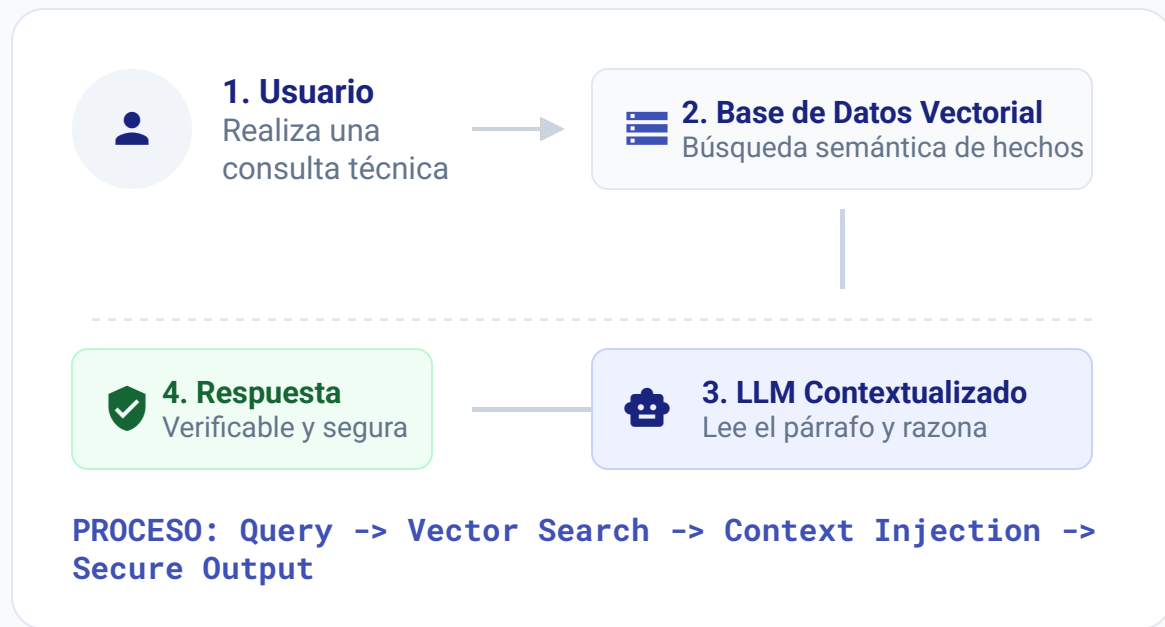



DIAGRAMA DE FLUJO RAG



Implicaciones Éticas

El despliegue de IA exige un compromiso ineludible con la legalidad, la privacidad y la integridad de los datos.

Privacidad y Copyright

Tratamiento estricto de datos personales y respeto a la propiedad intelectual en los sets de entrenamiento.

Sesgos Cognitivos

Identificación de estereotipos y discriminación incrustados en los embeddings para evitar algoritmos excluyentes.

"Un modelo es tan ético como los datos con los que fue alimentado y el propósito con el que fue diseñado."

EQUILIBRIO ÉTICO-LEGAL



UT 6. Procesamiento de Lenguaje Natural (PLN)

Curso de Especialización IA y Big Data