

Práctica 2: Arquitectura y Topología de Redes Neuronales

Herramienta: [TensorFlow Playground](#)

Objetivo: Desarrollar la intuición sobre cómo los hiperparámetros y la profundidad de la red afectan la capacidad de aprendizaje en problemas de clasificación.

Concepto: Test Loss

El *Test Loss* es un número que nos indica cuánto se equivoca la red neuronal al predecir datos que nunca ha visto antes. Es decir, es un "Contador de Fallos" en datos ocultos.

Para saber si la IA es inteligente de verdad, la herramienta hace un truco antes de empezar:

- De los 100 puntos que hay en pantalla, esconde 50 en un cajón (estos son los datos de Test o Prueba).
- Solo le enseña a la IA los otros 50 (estos son los datos de Training o Entrenamiento).

La IA empieza a pintar el fondo basándose solo en los 50 puntos que ve.

El **Test Loss** es el número que calcula lo siguiente:

La IA ha terminado de pintar. Ahora, sacamos los 50 puntos que habíamos escondido en el cajón y los ponemos sobre el dibujo que ha hecho la IA.

- Si un punto naranja "escondido" cae en la zona que la IA pintó de naranja → **Bien (El Loss baja)**.
- Si un punto naranja "escondido" cae en la zona que la IA pintó de azul → **Mal (El Loss sube)**.

En resumen:

El **Test Loss** es la **cantidad de error** que comete la IA con los puntos que **NO** le dejamos ver mientras estudiaba.

- **Test Loss alto:** La IA no sabe generalizar. Si le enseñas un punto nuevo, se equivoca de color.
- **Test Loss bajo (cercano a 0):** La IA ha entendido la lógica perfecta. Da igual qué puntos le escondas, sabe dónde deberían ir.

1. Instrucciones Generales

El objetivo no es solo lograr que la "Pérdida de prueba" (*Test Loss*) sea 0, sino hacerlo con la **arquitectura más simple posible** (principio de parsimonia). Una red gigante que resuelve un problema simple es una mala solución (ineficiente y propensa al *overfitting*).

Para cada uno de los 4 datasets de clasificación (Gaussian, Circle, XOR, Spiral), deberás encontrar una configuración exitosa y documentarla.

Configuración base obligatoria (a menos que el ejercicio pida cambiarla):

- **Regularization:** None
- **Regularization rate:** 0
- **Problem type:** Classification

2. Los Retos (Datasets)

Nivel 1: El problema lineal (Gaussian)

Este dataset son dos nubes de puntos separadas claramente.

- **Restricción:** Usa **0 capas ocultas** (conecta la entrada directamente a la salida).
- **Pregunta clave:** ¿Es necesario usar funciones de activación no lineales o capas ocultas para este problema? ¿Por qué?

Nivel 2: Círculos Concéntricos (Circle)

Aquí los datos no son linealmente separables.

- **Escenario A:** Mantén 0 capas ocultas, pero activa nuevas entradas como X^2 y Y^2 . Observa qué pasa.
- **Escenario B:** Usa sólo las entradas básicas (X_1 y X_2). Añade capas ocultas y neuronas. ¿Cuál es el mínimo necesario para rodear el círculo central?

Nivel 3: El problema XOR (Exclusive OR)

Un clásico de la computación. Dos cuadrantes positivos y dos negativos cruzados.

- **Reto:** Resuélvelo usando solo las entradas X_1 y X_2 .
- **Experimentación:** Prueba con una sola capa oculta ancha (ej. 8 neuronas) vs. dos capas ocultas estrechas (ej. 4 y 2 neuronas). ¿Cuál converge más rápido?

Nivel 4: La Espiral (Spiral)

El "Jefe Final". Es un problema altamente no lineal y difícil de converger para redes simples.

- **Consejo:** Aquí necesitarás jugar con la función de activación (prueba **ReLU** o **Tanh**, evita Sigmoid) y quizás ajustar el *Learning Rate*.
- **Objetivo:** Lograr un *Test loss* menor a 0.05.

3. Formato de Entrega (Informe Técnico)

Para cada uno de los 4 niveles, completa la siguiente ficha técnica. Debes justificar tus decisiones.

Parámetro	Configuración Elegida
Dataset	(Ej: Spiral)
Features (Entradas)	(Ej: $X_1, X_2, \sin(X_1) \dots$)
Capas Ocultas	(Ej: 2 capas)
Neuronas por capa	(Ej: Capa 1: 6, Capa 2: 4)
Función de Activación	(ReLU, Tanh, Sigmoid, Linear)
Learning Rate (tasa)	(Ej: 0.03)
Regularización	(Ninguna, L1, L2)
Test Loss Final	(Valor numérico tras la convergencia)

4. Preguntas de Reflexión

Responde brevemente al final de tu práctica:

1. **Activación:** En el problema de la "Espiral", ¿qué ocurre si intentas resolverlo utilizando una función de activación **Linear** en todas las capas, por muchas neuronas que añadas? ¿Por qué sucede esto matemáticamente?
2. **Overfitting:** En el dataset "Gaussian" (el más simple), configura una red gigante (4 capas, 8 neuronas cada una) y entrénala mucho tiempo. ¿Ves formas extrañas en la frontera de decisión o se mantiene suave? Explica el riesgo de usar modelos complejos en datos simples.
3. **Tasa de Aprendizaje:** ¿Qué sucede si pones un *Learning Rate* muy alto (ej. 10) o muy bajo (ej. 0.00001)? Describe el comportamiento visual.